

Slide 1 - Opening / Paper Overview

Suggested speaking time: ~35 seconds

متن فارسی برای ارائه شفاهی

سلام. در این ارائه، مقاله‌ی Qian و Pehlevan در ICLR 2026 با عنوان «Discovering Alternative Solutions Beyond the Simplicity Bias in Recurrent Neural Networks» را مرور می‌کنم. سؤال اصلی مقاله ساده اما مهم است: آیا دو RNN می‌توانند دقیقاً یک وظیفه را با عملکرد مشابه انجام دهند، اما از دینامیک درونی کاملاً متفاوتی استفاده کنند؟ این سؤال برای علوم اعصاب محاسباتی مهم است، چون RNN‌های آموزش‌دیده روی وظایف عصبی معمولاً به‌عنوان فرضیه‌هایی درباره‌ی سازوکار محاسباتی مغز استفاده می‌شوند. تمرکز من روی مسئله، روش INSD، نحوه‌ی اعتبارسنجی و مهم‌ترین نتایج مقاله است.

English speaking script

Hello. In this presentation, I will discuss the ICLR 2026 paper by Qian and Pehlevan, titled “Discovering Alternative Solutions Beyond the Simplicity Bias in Recurrent Neural Networks.” The central question is simple but important: can two RNNs solve exactly the same task with similar performance, while relying on fundamentally different internal dynamics? This matters in computational neuroscience because task-trained RNNs are often used as mechanistic hypotheses for how neural circuits may perform computations. I will focus on the problem, the proposed INSD method, how the authors validate the alternatives, and the main results.

Slide 2 - Problem: Simplicity Bias and Dynamic Collapse

Suggested speaking time: ~60 seconds

متن فارسی برای ارائه شفاهی

مسئله از اینجا شروع می‌شود که آموزش استاندارد RNN یک «سوگیری به سادگی» دارد. یعنی شبکه معمولاً به سمت راه‌حل‌های کم‌بعد و قابل‌تفسیر، مثل $\text{fixed-point attractor}$ یا slow manifold ها، می‌رود. این ویژگی ذاتاً بد نیست؛ مشکل زمانی ایجاد می‌شود که تقریباً همه‌ی شبکه‌ها، حتی با seed یا gain اولیه‌ی متفاوت، به همان الگوی دینامیکی برسند. نویسندگان این وضعیت را در چارچوب dynamic collapse مطرح می‌کنند: پارامترهای شبکه‌ها متفاوت‌اند، اما سازوکار محاسباتی آن‌ها عملاً یکی است. برای علوم اعصاب، این یعنی به‌جای چند فرضیه‌ی مکانیزمی مستقل، فقط چند نسخه‌ی متفاوت از یک فرضیه داریم. بنابراین تنوع پارامتری لزوماً به معنی تنوع مکانیزمی نیست.

English speaking script

The problem starts with the simplicity bias of standard RNN training. Networks tend to converge to simple, low-dimensional solutions, such as fixed-point attractors or slow manifolds. Simplicity itself is not a problem; these solutions are often interpretable. The problem is that many networks trained with different random seeds or different initialization gains can still converge to effectively the same dynamical motif. This is the idea of dynamic collapse: the parameter values may be different, but the underlying computation is essentially the same. For neuroscience, that limits the value of task-trained RNNs as competing mechanistic hypotheses. In short, parameter diversity does not necessarily imply mechanism diversity.

Slide 3 - What Counts as a Genuinely Different Solution?

Suggested speaking time: ~55 seconds

متن فارسی برای ارائه شفاهی

قبل از طراحی روش، باید مشخص شود «راه‌حل متفاوت» دقیقاً یعنی چه. مقاله سه شرط مهم دارد. اول، عملکرد وظیفه باید حفظ شود؛ اگر مدل جدید بدتر کار کند، صرفاً یک مدل ناموفق است. دوم، تفاوت‌های سطحی مثل جابه‌جایی نام نورون‌ها یا چرخاندن basis در فضای فعالیت، مکانیزم جدید محسوب نمی‌شوند، چون همان محاسبه را فقط با مختصات دیگری نمایش می‌دهند. سوم، مدل نباید با اضافه‌کردن فعالیت پرابعد و بی‌ربط، صرفاً معیار شباهت را فریب دهد. بنابراین هدف واقعی این است: همان تابع ورودی-خروجی، اما با محاسبه و دینامیک درونی واقعاً متفاوت.

English speaking script

Before proposing a method, the paper first clarifies what should count as a genuinely different solution. There are three requirements. First, the task function must be preserved; otherwise, the alternative is simply a worse model. Second, superficial transformations such as relabeling neurons or rotating the activity basis do not define a new mechanism, because the same computation is still present in different coordinates. Third, a model should not appear different only because it adds high-dimensional, task-irrelevant activity. So the real target is strict: preserve the same input-output function, while changing the internal computation in a way that cannot be explained by a trivial reparameterization or nuisance activity.

Slide 4 - Baseline: Standard RNN Training

Suggested speaking time: ~55 seconds

متن فارسی برای ارائه شفاهی

این اسلاید baseline را نشان می‌دهد. نویسندگان از یک RNN نرخ‌محور پیوسته استفاده می‌کنند: state شبکه با وزن‌های recurrent و ورودی تغییر می‌کند، firing rate با tanh به‌دست می‌آید، و خروجی یک readout خطی از فعالیت شبکه است. آموزش استاندارد فقط خطای میانگین مربعات بین خروجی و target را کمینه می‌کند. برای مقایسه، آن‌ها برای هر task یک جمعیت استاندارد می‌سازند: ده seed برای هر gain اولیه از مجموعه‌ی 0.01، 0.5، 1 و 1.5. نکته‌ی مهم این است که این objective فقط performance را بهینه می‌کند؛ هیچ فشاری برای پیدا کردن راه‌حل مکانیزمی متفاوت وجود ندارد.

English speaking script

This slide shows the baseline setup. The authors use a continuous-time rate RNN. The hidden state evolves through recurrent weights and external input, firing rates are obtained with a tanh nonlinearity, and the network output is a linear readout of those rates. Under standard training, the objective is simply the mean-squared error between the network output and the target. For comparison, the authors train a population of standard RNNs using ten random seeds for each initialization gain: 0.01, 0.5, 1.0, and 1.5. The key point is that this objective optimizes task performance only. It contains no explicit pressure to discover a mechanistically different solution.

Slide 5 - Proposed Method: Iterative Neural Similarity Deflation

Suggested speaking time: ~65 seconds

متن فارسی برای ارائه شفاهی

روش پیشنهادی مقاله Iterative Neural Similarity Deflation یا INSD است. ابتدا یک reference RNN فقط با task loss آموزش داده می‌شود. سپس برای Alternative 1، علاوه بر همان task loss، یک penalty اضافه می‌شود که شباهت فعالیت عصبی آن به reference را کم می‌کند. برای Alternative 2، شبکه هم‌زمان از راه‌حل reference و Alternative 1 دور می‌شود؛ و این فرایند می‌تواند به صورت تکراری ادامه پیدا کند. از نظر مفهومی، روش شبیه deflation یا یک ایده‌ی Gram-Schmidt در فضای راه‌حل‌های RNN است: هر مدل جدید باید task را حل کند، اما تا حد امکان از راه‌حل‌های قبلی قابل‌بازیابی نباشد. بنابراین INSD به جای امید بستن به seed متفاوت، مستقیماً تنوع مکانیزمی را وارد objective می‌کند.

English speaking script

The proposed method is Iterative Neural Similarity Deflation, or INSD. First, a reference RNN is trained using the ordinary task loss. Then, Alternative 1 is trained with the same task loss plus a penalty that discourages similarity to the reference network's neural activity. For Alternative 2, the loss penalizes similarity to both the reference and Alternative 1, and the procedure can continue iteratively. Conceptually, this resembles a deflation procedure, or a Gram-Schmidt-like idea in the space of RNN solutions: each new model must still solve the task, but it is explicitly pushed away from solutions that have already been found. So, instead of hoping that a different seed produces a different mechanism, INSD directly builds mechanism diversity into the training objective.

Slide 6 - Critical Design Choice: Penalize the Readout Nullspace

Suggested speaking time: ~60 seconds

متن فارسی برای ارائه شفاهی

یک انتخاب کلیدی این است که penalty روی کل فعالیت شبکه اعمال نمی‌شود. فعالیت را می‌توان به دو بخش تقسیم کرد. بخش output-potent مستقیماً روی خروجی اثر می‌گذارد؛ چون همه‌ی مدل‌ها باید همان target را تولید کنند، این بخش تا حدی مجبور است بین راه‌حل‌ها مشترک باشد. اگر این قسمت را هم متفاوت کنیم، احتمالاً performance خراب می‌شود. در مقابل، readout nullspace شامل فعالیتی است که readout خطی آن را نمی‌بیند و مستقیماً خروجی را تغییر نمی‌دهد. بنابراین نویسندگان similarity penalty را فقط در nullspace اعمال می‌کنند. ایده این است: محاسبه‌ی لازم برای خروجی را حفظ کن، اما در درجات آزادی پنهان، مدل را مجبور کن یک دینامیک درونی متفاوت پیدا کند.

English speaking script

A critical design choice is that the similarity penalty is not applied to all neural activity. The activity can be decomposed into an output-potent component and the readout nullspace. The output-potent component directly determines the output. Because all models must produce the same target, this component is necessarily constrained and must remain partly similar across solutions. Penalizing it would work against task performance. The readout nullspace, in contrast, contains activity that does not directly affect the linear output. That is where alternative internal dynamics can exist without changing the required behavior. Therefore, INSD applies the similarity penalty only in the readout nullspace: preserve the computation required for the output, but diversify the hidden dynamics that are free to vary.

Slide 7 - Similarity Metric: Asymmetric Linear Predictivity

Suggested speaking time: ~60 seconds

متن فارسی برای ارائه شفاهی

برای اندازه‌گیری شباهت، نویسندگان از linear predictivity استفاده می‌کنند و جهت آن عمداً نامتقارن است. سؤال این است: آیا فعالیت nullspace راهحل قبلی را می‌توان با یک نگاشت خطی از فعالیت nullspace مدل جدید بازسازی کرد؟ اگر پاسخ بله باشد، مکانیزم قبلی هنوز داخل مدل جدید پنهان شده و باید جریمه شود. چرا این جهت مهم است؟ چون یک مدل candidate می‌تواند همان راهحل قدیمی را نگه دارد و فقط چند dimension بی‌ربط به آن اضافه کند؛ در این حالت بعضی معیارهای متقارن ممکن است تفاوت مصنوعی گزارش کنند. اما اگر از مدل جدید به مدل قبلی پیش‌بینی کنیم، وجود همان راهحل قدیمی همچنان قابل‌بازیابی است. پس penalty دقیقاً reuse پنهان مکانیزم قبلی را هدف می‌گیرد.

English speaking script

To measure similarity, the authors use linear predictivity, and the direction is deliberately asymmetric. The question is: can the previous solution's nullspace activity be linearly reconstructed from the new network's nullspace activity? If it can, then the old mechanism is still embedded inside the new model and should be penalized. Why is the direction important? A candidate network could preserve the old solution and simply add extra task-irrelevant dimensions. Some symmetric similarity measures can then report a large difference even though the original mechanism is still present. By predicting from the new solution back to the previous one, hidden reuse remains detectable. The penalty therefore targets recoverability of the old nullspace solution from the new RNN.

Slide 8 - Validation: Ruling Out Cosmetic Differences

Suggested speaking time: ~55 seconds

متن فارسی برای ارائه شفاهی

برای نشان دادن اینکه تفاوت‌ها صرفاً ظاهری نیستند، مقاله INSD را روی سه task بررسی می‌کند: context-dependent integration, 3-bit flip-flop و MemoryPro. اعتبارسنجی در سه سطح انجام می‌شود. در سطح representation، از linear predictivity و decoding خطی در برابر RBF استفاده می‌شود. در سطح fixed point و slow point dynamics، eigenmode ها و Dynamical Similarity Analysis یا DSA بررسی می‌شوند. و در سطح function، مدل‌ها در شرایط خارج از توزیع آموزش، مثل نویز بیشتر، trial طولانی‌تر یا memory load بالاتر آزمایش می‌شوند. بنابراین سؤال فقط این نیست که نمودارهای PCA متفاوت به نظر می‌رسند؛ سؤال این است که آیا dynamics، representation و رفتار مقاومتی واقعاً متفاوت شده‌اند.

English speaking script

To show that the alternatives are not merely cosmetic, the paper evaluates INSD on three tasks: context-dependent integration, the 3-bit flip-flop, and MemoryPro. Validation is performed at three levels. At the representation level, the authors use linear predictivity and compare linear versus nonlinear, RBF-based decoding. At the dynamical level, they analyze fixed and slow points, local eigenmodes, and Dynamical Similarity Analysis, or DSA. Finally, at the functional level, they test the networks under conditions that differ from training, such as stronger noise, longer trials, or higher memory load. So the validation question is not simply whether the PCA plots look different; it is whether the representation, the dynamical mechanism, and the robustness profile are genuinely different.

Slide 9 - Results: Same Function, Different Dynamical Mechanism

Suggested speaking time: ~70 seconds

متن فارسی برای ارائه شفاهی

نتیجه‌ی اصلی این اسلاید این است که INSD واقعاً نوع دینامیک را تغییر می‌دهد. در context-dependent integration، RNN استاندارد از line attractor یا مجموعه‌ای از slow point‌ها برای انتگرال‌گیری استفاده می‌کند؛ اما Alternative 1 دینامیک نوسانی ایجاد می‌کند و اطلاعات را بدون حرکت روی همان slow manifold نگه می‌دارد. در MemoryPro، راه‌حل استاندارد حافظه را با یک ring attractor و کد تقریباً ایستا حفظ می‌کند. در مدل جایگزین، ring ثابت از بین می‌رود و نمایش حافظه به یک کد چرخشی و پویا تبدیل می‌شود، در حالی که اطلاعات لازم برای پاسخ حفظ شده است. در 3-bit flip-flop نیز مدل‌های جایگزین می‌توانند حالت‌های حافظه را بدون همان مجموعه‌ی attractorهای پایدار استاندارد نگه دارند. پس این فقط تغییر شکل representation نیست؛ همان function با مکانیزم دینامیکی متفاوت پیاده‌سازی شده است.

English speaking script

The main result here is that INSD changes the type of dynamics, not just the appearance of the representation. In context-dependent integration, the standard RNN uses line-attractor-like slow points to integrate the relevant input. Alternative 1 instead develops oscillatory dynamics and maintains the required information without moving along the same slow manifold. In MemoryPro, the standard solution stores the remembered angle using a ring attractor and a largely static code. The alternative loses this persistent ring and uses rotating, dynamic activity while still preserving the information needed for the response. The 3-bit flip-flop shows the same general pattern: alternative networks can maintain discrete memory states without relying on the standard set of stable fixed-point attractors. So the key result is the same function, implemented by a different dynamical mechanism.

Slide 10 - Results, Robustness, and Takeaway

Suggested speaking time: ~65 seconds

متن فارسی برای ارائه شفاهی

آخرین نتیجه این است که مکانیزم‌های متفاوت، robustness profile متفاوت هم دارند. در شرایط نزدیک به training، RNN‌های استاندارد معمولاً بهتر عمل می‌کنند. اما در بعضی شرایط دشوار، راه‌حل‌های INSD برتری دارند: مثلاً alt-2 در context-dependent integration تحت نویز زیاد، و در flip-flop نیز در نویز بالا، عملکرد بهتری نشان می‌دهد. در MemoryPro، alt-1 در ترکیب نویز زیاد و memory load بالا بهتر است، هرچند در memory load پایین ضعیف‌تر عمل می‌کند. پس INSD «بهتر» به صورت مطلق نیست؛ trade-off متفاوت ایجاد می‌کند و همین تفاوت عملکردی شواهد دیگری برای متفاوت بودن مکانیزم‌هاست. caveat مهم مقاله هم این است که متفاوت بودن لزوماً به معنی biologically realistic بودن نیست. جمع‌بندی: INSD فضای فرضیه‌های قابل‌دسترس برای محاسبات بازگشتی را فراتر از راه‌حل‌های ساده‌ی حاصل از آموزش استاندارد گسترش می‌دهد. سپس: ممنون از توجه شما؛ خوشحال می‌شوم به سؤال‌ها پاسخ دهم.

English speaking script

The final result is that different mechanisms also have different robustness profiles. Near the training regime, standard RNNs usually perform best. But under some difficult conditions, INSD solutions do better. For example, alt-2 is more robust to high noise in context-dependent integration, and it also shows a moderate advantage at high noise in the flip-flop task. In MemoryPro, alt-1 performs better on the most difficult combination of high noise and high memory load, although it performs worse at low memory loads. So INSD is not universally better; it creates different functional trade-offs, which is further evidence that the mechanisms are genuinely distinct. The important caveat is that different does not automatically mean more biologically realistic. The main takeaway is that INSD expands the accessible hypothesis space of recurrent neural computation beyond the solutions found by standard training. Thank you for your attention. I would be happy to answer any questions.